

INGENIERIA EN COMPUTACION INTELIGENTE.

INFORME DE AVANCES DEL TRABAJO DE INVESTIGACIÓN.

SEMINARIO DE INVESTIGACIÓN II.

Nombre del proyecto: Modelo predictivo y detección de anomalías para la optimización de la ejecución de reportes en instancias IaaS

Nombre del tesista Dante Alejandro Alegria Romero

Generación: 2/22/2026 Fecha de revisión: _____ No. de Informe Semana 4

Actividades comprometidas:

Selección y validación de métricas de error: Establecer los criterios estadísticos (MAE, RMSE, MASE) para medir la precisión del forecasting de acuerdo con el estado del arte.

Desarrollo del modelo de Forecasting (Fase II): Implementar una solución avanzada que supere el baseline de estacionalidad simple.

Validación de modelos mediante Backtesting: Realizar pruebas de rendimiento histórico para asegurar la estabilidad de las predicciones.

Documentación técnica y Dashboard: Estructurar la visualización de resultados de entrenamiento para su revisión académica.

Actividades Realizadas

Implementación del indicador MASE y Modelos Base: Se programó el cálculo de MASE para horizontes de 24h y 168h (obteniendo 0.5540). Se integró un script de *baseline* (modelos ingenuos) para contrastar formalmente la ganancia de precisión de los modelos avanzados.

Arquitectura Híbrida Prophet + XGBoost con Regresión Cuantílica: Se finalizó el modelo híbrido donde Prophet extrae componentes estacionales y XGBoost ajusta residuos. Se añadió regresión cuantílica (p10, p50, p90) para estimar la incertidumbre y ofrecer intervalos de confianza en las predicciones de carga.

Detección de Anomalías Multivariante: Se implementó el algoritmo Isolation Forest para trabajar en conjunto con el método MAD (Median Absolute Deviation), permitiendo identificar irregularidades complejas en el volumen de reportes y tiempos de ejecución.

Enriquecimiento del Pipeline de Datos (Feature Engineering): Se extendió el procesamiento de datos incluyendo:

- Cálculo de *backlog* (cola de espera).

- Transformadas de Fourier y codificaciones cíclicas para capturar periodicidad.
- Pruebas de KS Drift Detection (Kolmogorov-Smirnov) para monitorear desplazamientos en la distribución de los datos y detectar pérdida de vigencia del modelo.

Integración de Contexto Operativo (Git Tracking): Se desarrolló un módulo de utilidades para recuperar el historial de *commits* del repositorio de reportes, permitiendo realizar análisis de causa raíz al correlacionar cambios en el código con anomalías en el rendimiento.

Expansión del Dashboard Académico: Se crearon 10 nuevas secciones en Streamlit que cubren: análisis de series temporales, comparativa de modelos, diagnósticos de residuos, recomendaciones de cola de ejecución y un modo de presentación para anonimización de datos sensibles.

decisiones.

Observaciones

Dr. Francisco Javier Ornelas Zapata

Nombre y firma del Tutor.

Alejandro Padilla Diaz

Nombre y firma del Profesor.



Dante Alejandro Alegria Romero

Nombre y firma del Alumno.